Technical Bluebook

企业级人工智能安全技术蓝皮书

统一 AI 安全控制面、解耦安全与评测框架

Scope. Unified AI Security Control Plane • Decoupled Safety • Evaluation Framework

Purpose. Establish a rigorous, enterprise-grade technical blueprint for controllable, auditable, and evolvable AI security.

Author(s)	王云浩等
Organization	数字信任 / 天木 / AI 安全研究

Version	v1.0-草案
Date	April 23, 2026
Classification	内部草案
Keywords	AI 安全; 统一控制面; 解耦安全; 运行时强制; 评测框架

本蓝皮书阐述面向企业级 AI 系统的统一控制面架构、解耦安全模型与以证据为中心的评测方法。推荐使用 XeLaTeX 编译。

Contents

1 统一 AI 安全控制面：问题陈述与系统边界 . . . 2
1.1 战略背景与企业级转型 . . . 2
1.2 系统边界与责任划分 . . . 2
1.3 资产、对手模型与运行假设 . . . 2
1.4 安全目标与权衡 . . . 3

2 解耦安全：概念基础与安全模型 . . . 4
2.1 仅以模型为中心的安全叙事之局限 . . . 4
2.2 安全模型抽象 . . . 4
2.3 典型失效模式 . . . 4

3 参考架构与解耦安全内核 . . . 6
3.1 分层参考架构 . . . 6
3.2 数据面、控制面与证据面 . . . 6
3.3 Decoupled Safety Kernel 接口 . . . 6

4 运行时强制与策略编排 . . . 8
4.1 风险自适应控制闭环 . . . 8
4.2 策略决策生命周期 . . . 8
4.3 检索安全（RAG） . . . 8
4.4 工具调用控制 . . . 9
4.5 升级、降级与人机协同 . . . 9

5 评测框架：安全、效用与系统保证 . . . 10
5.1 语义、基准与验收契约 . . . 10
5.2 指标分层 . . . 10
5.3 共享基础设施下的多轨评测 . . . 10
5.4 协议：离线、在线、回归与发布 . . . 11

6 治理、部署与研究路线 . . . 12
6.1 证据图谱与发布治理 . . . 12
6.2 组织运作模型 . . . 12
6.3 分阶段部署路线 . . . 12
6.4 研究路线 . . . 13

A 地域化与多语言评测 . . . 14

B 术语与角色边界 . . . 15

Abstract. 本蓝皮书提出企业级 AI 安全的统一架构与评测蓝图，并围绕三条相互支撑的主线组织论述：（i）Unified AI Security Control Plane，在 AI 全生命周期内将安全决策外显化、可编排地执行；（ii）Decoupled Safety，将安全视为可组合、可审计的显式控制层，而非埋藏于单一模型参数中的隐式属性；（iii）严格的 Evaluation Framework，不仅度量抗攻击能力，还度量可控性、效用保持、可审计性与运营可持续性。核心论点是：企业级 AI 安全属于控制面问题——保证须由可组合的运行时强制与可度量证据共同提供，而不能仅依赖静态的模型对齐假设。

Executive Summary

- **背景**。生产环境 AI 正从孤立模型端点转向复合系统：编排、检索增强生成（RAG）、工具、记忆与多轮智能体。失效模式覆盖机密性、完整性、可用性与运营治理，而不仅是有害输出。
- **问题**。能力扩张速度已快于企业在非确定性与持续变更下实现一致策略执行、审计可追溯与可发布级保证的机制能力。
- **核心主张**。安全约束应通过可外显、可组合、可审计的 Unified AI Security Control Plane 与 Decoupled Safety Kernel 落实，覆盖输入、检索、推理、输出与工具调用。模型对齐是必要但非充分条件；Decoupled Safety 使义务可声明、可测试。
- **证据主张**。任何安全声明须由 Evaluation Framework 支撑，将基准、验收契约、在线遥测、红队、回归与发布物绑定为同一条证据链。
- **交付物**。参考威胁模型与目标；分层参考架构；含 RAG 与工具调用的运行时策略编排模式；安全/效用/系统/治理维度的指标矩阵；分阶段部署与研究路线；以及关于法域化评测模式与术语边界的附录。

Chapter 1

统一 AI 安全控制面：问题陈述与系统边界

Chapter Objective

本章将企业级 AI 安全问题明确为控制面问题。**主线聚焦：**Unified AI Security Control Plane。阐述战略背景、安全判断与执行平台之间的形式边界、对手假设，以及含机密性、完整性、可用性在内的可度量安全目标，并论及与可控性、可审计性等之间的权衡。

Deliverables

- 问题陈述与范围；系统边界与信任假设。
- 与运行时控制点对齐的结构化威胁模型。
- 安全目标（CIA 与可控性、可审计性、可组合性、效用保持）及显式权衡。

1.1 战略背景与企业级转型

主线：Unified AI Security Control Plane。企业级 AI 部署日益呈现分布式系统特征：接入网关、路由、检索索引、向量库、工作流引擎、插件以及人工环节。风险因此是系统性的：提示注入跨越信任边界；被投毒语料操纵答案；工具链连接至高权限操作；编排状态带来跨轮次攻击；日志缺失则消灭可问责性。若将传统应用安全与内容安全能力作松耦合附加，则无法在上述全路径上提供统一的强制与证据标准。

1.2 系统边界与责任划分

主线：Unified AI Security Control Plane。本蓝皮书区分两类责任：（i）安全判断——策略解释、风险评分、允许/拒绝/改写决策、可解释性载荷与证据输出；（ii）执行平台——网络、扩缩容、编排 SLA 与负载放置。Unified AI Security Control Plane 必须在语义上锚定策略与证据，而非退化为「仅谈模型」或「仅谈泛化基础设施」的叙述。外部语境（文档、工具、API）属于攻击面的一部分，须纳入同一套控制与可追溯性包络。

Problem Statement

核心问题不仅是在隔离条件下使单模型表现安全，而是：在动态语境注入、外部检索、工具调用、记忆与状态、以及异构部署约束下，如何使以 LLM 为中心的系统持续处于可声明、可审计的风险边界之内。答案不是与测量、发布脱节的「更多检测器」，而是贯穿风险统一语义、确定性强制挂点、以及可产生可发布级证据的评测体系相联通的控制面。

1.3 资产、对手模型与运行假设

主线： Unified AI Security Control Plane / Evaluation Framework。受保护资产包括：用户与企业数据的机密性，提示与检索内容的完整性，工具侧效果与参数完整性与不可否认性，服务在 SLA 内的可用性，以及审计记录的完整性。考虑的对手包括：构造对抗性提示；经检索信道投毒或泄露；滥用或串联工具调用；操纵会话与工作流状态；滥用运营面（如文档中的隐匿指令）。内部威胁主要通过职责分离、证据不可篡改与工具最小权限来缓解——而非仅靠模型对齐。

运行假设包括：策略可以机器可核验的片段表述；在网关、检索、推理、工具与日志层存在强制挂点；部分残余风险通过验收契约明示接受；非确定性须由统计检验计划与在线监控界定，而不能被笼统忽略。

Threat Model

Threat Surface	Adversary Goal	Attack Pattern	Potential Impact	Control Point
提示交互面	策略绕过或经指令的数据渗出	越狱、分隔符攻击、间接提示注入	策略失效、数据泄露、特权滥用	输入治理、规范化、指令边界
检索路径	语料操纵 / 敏感信息暴露	投毒、冲突来源、文中注入指令	错误或有害答案、泄漏、合规失败	检索安全、血缘、分段、引用绑定
工具调用层	特权提升	工具链攻击、伪造参数、模糊审批	数据损毁、财务或运营影响、横向移动	工具策略、审批、沙箱、限速
模型执行层	善意意图下的不安全生成	对齐尖峰、事实幻觉	有害内容、不可靠自动化	输出治理、事实锚定(grounding)约束、校准弃权
运行时编排	控制面不一致	跨轮状态操纵、陈旧策略绑定	静默策略漂移、审计断裂	策略引擎版本化、原子化决策日志

1.4 安全目标与权衡

主线： Unified AI Security Control Plane / Evaluation Framework。以下目标在系统层面须一并满足；彼此之间的张力应可度量、可作为策略议题加以管理。

Security Objectives

- **机密性（Confidentiality）**。敏感企业与用户数据不得逾越策略经提示、检索、日志或工具输出泄露信任边界。
- **完整性（Integrity）**。在威胁假设范围内，提示、检索片段、工具参数及侧效果须具完整性保障；篡改须在审计证据上可被发现。
- **可用性（Availability）**。安全控制在时延与吞吐包络内维持业务可用；降级须可度量、可控。

- **可控性（Controllability）**。高风险行为须能通过显式运行时策略加以约束，而非仅靠隐式模型习性。
- **可审计性（Auditability）**。与策略相关的决策须产生适于回放、治理复盘与回归测试的结构化证据。
- **可组合性（Composability）**。控制在异构模型、版本与栈之上仍有效，而不与单一检查点文件强耦合。
- **效用保持（Utility Preservation）**。安全干预将对合法任务成功的无谓损害最小化；无谓拦截视为可度量缺陷。

权衡。强拦截有利于完整性与机密性指标，但可能压低效用与可用性；检索分段有利于机密性，但可能降低答案完备性；审计加深有利于治理指标，但消耗存储与时延预算。Decoupled Safety 的宗旨正是将这些权衡政策化、版本化、可举证，而非停留于即兴调参。

Design Principle

解耦. 安全逻辑从任一单模型中外置，经由显式策略接口并由 Decoupled Safety Kernel 强制执行。

Design Principle

跨层强制. 控制在输入、检索、推理、工具、输出与治理日志上构成连贯包络。

Design Principle

证据先于信任. 任何保证声明须有测试、遥测或审计制品支撑，并足以支撑发布决策。

Key Takeaway

Unified AI Security Control Plane 是使企业级 AI 安全可运营强制、模型无关且随栈与策略演进而可进化的架构单元。

Chapter 2

解耦安全：概念基础与安全模型

Chapter Objective

本章形式化阐述 Decoupled Safety：安全作为外置、可组合且在模型偏好之上具显式优先级的控制层。**主线聚焦：**Decoupled Safety。界定概念、不变式，以及在将安全误认为模型内生属性时的典型失效模式。

Deliverables

- 策略优先与可组合性强制的定义与不变式。
- 将「对齐等同于系统安全」时的失效模式。
- 从概念模型到内核级强制的衔接（第 3 章展开）。

2.1 仅以模型为中心的安全叙事之局限

主线：Decoupled Safety。对齐与指令微调可降低基线有害补全率，但在检索、工具、对抗语境或编排条件下无法单独建立系统级保证。模型在离线评测中看似「安全」，一旦接入携带对抗指令的语料、具有真实副作用的工具或跨轮累积不安全状态的工作流，仍可能失效。

Definition 2.1 (解耦安全)**.** Decoupled Safety 指：安全约束在与任一具体模型内部参数相分离的专用控制层中表示、强制执行并接受审计的设计原则。策略层对外暴露稳定接口（事件、义务、决策），而不绑定于特定提供商的检查点格式。

Invariant 2.2 (策略优先)**.** 若生成偏好与显式安全策略冲突，必须以策略层支配最终系统行为；部分结果（如改写或删节输出）仍须满足策略。

Invariant 2.3 (组合式黑盒接口)**.** 强制执行消费类型化的安全事件（输入、检索单元、工具调用、候选输出），并产出决策与证据记录。下游模块不得在缺乏可审计升级路径的情况下绕过上述决策。

2.2 安全模型抽象

主线：Decoupled Safety。为便于实现与评测，将四类对象区分：策略 P（义务与阈值）、强制执行内核 K（护栏、路由器、工具门控、编排挂钩）、环境 E（部署拓扑与信任域）、证据 Ev（可审计轨迹）。更换模型检查点应主要改变生成统计特性；若无配套证据更新，不得静默使 P 失效。

2.3 典型失效模式

Risk / Threat

归属模糊. 安全逻辑隐匿于提示词或模型权重中时，升级会在无回归检测的情况下静默改写有效策略。

Risk / Threat

编排绕检. 智能体与工作流通过备用工具或隐式信道绕开护栏；缺乏编排绑定强制时一致性崩溃。

Risk / Threat

证据缺失. 运营方无法复原为何作出某决策，审计、复盘与从事故中学习受阻。

Open Problem / Research Agenda

基础问题. 在异构模型、非确定解码与多步工具使用下，哪些类别的组合式安全约束可在可度量误差界内被强制执行?

Key Takeaway

Decoupled Safety 将安全从训练的涌现属性转化为可工程化的对象：策略、内核、证据与评测。

Chapter 3

参考架构与解耦安全内核

Chapter Objective

本章给出 Unified AI Security Control Plane 的参考架构，并分解 Decoupled Safety Kernel 的功能边界。**主线：** Unified AI Security Control Plane + Decoupled Safety。阐述分层职责，以及支撑可审计性所需的数据面、控制面与证据面并行流动。

Deliverables

- 从交互层到治理层的分层架构。
- 策略引擎、护栏、检索中介、工具控制、审计面等模块接口。
- 初始交付物与阶段归属（详见第 6 章）。

3.1 分层参考架构

主线： Unified AI Security Control Plane。架构按层划分职责：

- **交互层：** 用户与应用输入、认证与租户语境、会话管理、请求整形。
- **语境层：** 提示理解、路由、检索规划、血缘绑定、按敏感度与用途对语料分段。
- **模型执行层：** 模型路由、解码控制、事实锚定挂钩、在可用时的弃权与不确定性信号。
- **运行时强制层：** 策略引擎、护栏、检索中介、响应过滤、工具门控、确定性改写与删节、升级处置。
- **治理层：** 证据存储、评测流水线、发布闸、监控、事件回放、策略生命周期管理。

3.2 数据面、控制面与证据面

主线： Unified AI Security Control Plane。数据面承载提示、检索文本、嵌入元数据、工具请求与响应及补全。控制面承载策略、决策、义务、路由结果、风险评分与升级状态。证据面跨系统绑定标识符：策略版本、模型路由、检索语料切片、检测器版本、适当时的提示与文档哈希、决策与人工审批。保证论述依赖跨平面关联证据记录。

3.3 Decoupled Safety Kernel 接口

主线： Decoupled Safety。Decoupled Safety Kernel 暴露窄幅稳定接口以使强制可组合：

- **事件接入**。对输入、检索命中、候选补全、工具调用等进行规范化事件。
- **策略求值**。在定义事件上对版本化规则集与阈值做确定性求值。

- **动作派发**。允许、改写、约束、沙箱、升级、阻断、降级，并携带类型化参数。
- **证据发射**。输出可供 Evaluation Framework 与治理工具消费的结构化记录。

Module	Deliverable	Acceptance Criteria	Owner	Phase
策略引擎	模式 + 规则 + 决策轨迹	对约定事件类型可确定性回放	运行时策略	P1
输入/输出 Guardrails	分类器、校验器、改写模板	相对基线可测的绕过率下降	安全 ML	P1
检索安全服务	语料标注、引用绑定、检索白名单	注入/投毒实际危害下降	平台 + 应用	P1
工具控制器	能力矩阵、同意书、审批、沙箱	高风险动作须有显式策略路径	智能体平台	P2
审计面	仅追加日志、关联标识	可由证据完整复原事件	平台 SRE	P2
评测服务	套件、看板、回归	版本化包满足发布闸	质量保证	P1

Key Takeaway

Decoupled Safety Kernel 将 Decoupled Safety 落实为可实现接口：类型化事件、确定性决策与适于治理的证据。

Chapter 4

运行时强制与策略编排

Chapter Objective

本章端到端说明策略如何强制执行，包括风险自适应控制选择、检索与工具中介，以及人机协同升级。**主线：** Unified AI Security Control Plane + Decoupled Safety。将第 2 章概念模型与可度量运行时行为相连。

Deliverables

- 风险信号、策略绑定、干预、日志与向评测的反馈。
- RAG 与工具调用的具体强制模式与安全降级。

4.1 风险自适应控制闭环

主线： Unified AI Security Control Plane。在线强制与保证闭环对齐：

1. **测量（Measure）**。离线/在线测量产生决策信号（攻击成功率、漂移、拒绝质量、时延等）。
2. **画像（Profile）**。按模型与场景汇总风险暴露，给定部署语境。
3. **选择（Select）**。在风险、成本、时延与业务容忍度约束下选择控制深度（规则对轻量检测对重型检测；工具约束；检索分段）。
4. **强制（Enforce）**。经由 Decoupled Safety Kernel 接口确定性施加动作。
5. **证据与反馈**。发射审计记录；失效驱动基准更新、红队优先级与策略修订。

4.2 策略决策生命周期

主线： Decoupled Safety。单次请求维度：

1. 审视请求并提取风险信号（主题敏感度、信道信任、检索范围、工具暴露）。
2. 将请求绑定到适用的策略包与版本（租户、地理、负载类别）。
3. 评估干预：允许、改写、约束、沙箱、升级、阻断、降级，并给出显式理由码。
4. 记录决策及可回放的相关证据载荷。
5. 将事件与未遂注入离线套件与影子评测。

4.3 检索安全（RAG）

主线： Unified AI Security Control Plane。检索将第三方文本带入提示边界；应将检索片段视为不可信、类代码内容。控制包括：语料分段（公开与机密）、元数据与血缘要求、检索时过滤、

与段落绑定的引用、矛盾处理、自敏感切片导出答案的最大特权范围、以及批量与在线投毒检测挂钩。检索策略须与包含投毒文档场景的评测协同演化。

4.4 工具调用控制

主线： Unified AI Security Control Plane。工具将语言映射为副作用；须按租户与工作流执行能力矩阵、参数类型校验、高影响动作的动态审批、可行时的沙箱执行、持久限速，以及只读与变更类工具的分离。编排器不得构造绕过已记录决策的平行路径。

4.5 升级、降级与人机协同

主线： Decoupled Safety。当自动化置信不足时，升级路径包括：受限执行（安全模板）、部分答案、带 sla 的人工审批队列、以及用于训练与策略迭代的事故捕获。降级策略本身亦须受策略治理，避免静默削弱安全态势。

Evaluation / Assurance

运行时保证目标. 每条干预路径须配对指标：残余风险、效用影响、时延增量与审计完整性。

Key Takeaway

运行时强制将 Decoupled Safety 体现为真实事件上的可度量决策，而非与证据脱节的静态配置。

Chapter 5

评测框架：安全、效用与系统保证

Chapter Objective

本章将 Evaluation Framework 定义为 Unified AI Security Control Plane 的证据引擎。**主线：**Evaluation Framework。阐明基准语义、验收契约、跨安全与效用的指标体系、共享基础设施下的多轨评测，以及可发布级证据包。

Deliverables

- 指标类别与能力—测试映射。
- 与发布闸相连的离线、影子、对抗与回归工作流。
- 审计完整性与策略符合性的治理指标。

5.1 语义、基准与验收契约

主线：Evaluation Framework。风险须在统一分类体系下关联检测类别、评分量表与义务。基准宪章（*benchmark constitution*）声明覆盖期望（须测量哪些失效类别及聚合方式）。验收契约（*acceptance contract*）将场景绑定阈值与例外，把测量转化为各部署阶段的准入条件。契约与策略包、检测器包联合版本化。

5.2 指标分层

主线：Evaluation Framework。在四个互补层次上评测：

- **安全**。攻击成功概率、绕过率、注入影响、不安全工具调用、渗出企图。
- **效用**。任务成功率、在有标注处的正确性、有用性代理、校准的拒绝行为、适用时的过度拒绝率。
- **系统**。时延开销、吞吐影响、内存与计算成本、负载下稳定性。
- **治理**。轨迹完整性、回放保真度、不可篡改校验、策略绑定正确性、事件下钻能力。

5.3 共享基础设施下的多轨评测

主线：Evaluation Framework。不同监管或组织义务不必坍缩为单一分数。可行模式是：共享执行主干（运行定义、目标、制品、结果存储、CI/CD 挂钩）配以在套件、聚合逻辑与报告模板上各异的多条评测轨，同时在发布决策上汇入统一决策面板。法域专属轨道（例如带本地化案例库的监管类别）宜作为一等公民，而非全球套件的薄翻译；证据包须显式引用轨道标识。

Evaluation Criteria

Capability	Security Metric	Utility Metric	System Metric	Evidence / Benchmark
输入/输出 Guardrails	绕过率、有害漏检	任务完成、用户摩擦	附加时延、尾延迟	红队提示、自适应攻击
检索控制	投毒命中率、未授权切片访问	答案正确性/有用性	检索时延、索引成本	投毒语料、注入文档
工具调用控制	不安全动作率、特权滥用	工作流成功率	审批时延	智能体攻击、工具链
多轨/区域套件	轨道专属通过阈值	可比的效用基线	运行成本、运营耗时	本地化套件 + 共享底座
审计/证据面	轨迹完整性、回放成功	根因定位耗时	存储、日志体量	事件回放演练、抽样审计

5.4 协议：离线、在线、回归与发布

主线： Evaluation Framework。**离线**套件驱动迭代与阻断缺陷；**影子**部署在可控风险下对比线上流量形态下的策略变体；**红队**探测自适应攻击模型；**回归**闸在策略、模型或检测器变更时对标准包施加单调改进类约束。发布标准组合统计阈值、最坏情形上限、必备证据制品与运维签批规则。

Open Problem / Research Agenda

评测前沿. 在非确定解码与策略干预下，组织如何在可度量置信区间约束下联合优化安全、效用、成本、时延与可审计性?

Key Takeaway

Evaluation Framework 将主观判断转化为证据：版本化套件、显式契约与可与 Unified AI Security Control Plane 一道经受审计与发布辩护的关联遥测。

Chapter 6

治理、部署与研究路线

Chapter Objective

本章将蓝图可操作化：以证据为中心的治理、分阶段交付、角色分工与精炼研究议程。**主线：** Unified AI Security Control Plane、Decoupled Safety、Evaluation Framework 的综合，从工程闭环到保证文化。

Deliverables

- 分阶段路线与交付物、验收锚点。
- 统一安全科学、运行时内核、证据/CI/发布与多语智能的运作模型。
- 与组合式运行时安全及不确定性下保证相关的研究主题。

6.1 证据图谱与发布治理

主线： Evaluation Framework / Unified AI Security Control Plane。发布决策依赖连接基准运行、策略版本、模型路由、检测器版本、代表性遥测切片与人工审批的证据图谱。图谱须支持差分更新：仅子系统变更时的部分重跑。治理通过显式验收契约整合法务、隐私与安全相关方，而非仅依赖临时会议。

6.2 组织运作模型

主线： 综合。高效项目持续对齐四类能力：（i）安全科学与基准治理；（ii）运行时 Decoupled Safety Kernel 工程；（iii）证据、CI/CD 与发布闸；（iv）多语与地域化智能——作为语义测试与检测器的源头，而非事后补丁。目标是理论、系统、基准与运营的共同演化，而非孤立团队优化局部指标。

6.3 分阶段部署路线

- **第一阶段——基线包络**。输入/输出 Guardrails、结构化审计日志、面向最高风险场景的极简验收契约与回归套件。
- **第二阶段——语境风险**。检索中介、工具策略、扩展的证据关联、影子评测。
- **第三阶段——统一控制面**。跨模型策略抽象、中心化策略生命周期、决策与证据的一体化看板。
- **第四阶段——自适应保证**。具形式目标的风险自适应选择、回归发现自动化加强、在可行处的定向验证实验。

Module	Deliverable	Acceptance Criteria	Owner	Phase
基准宪章	成文档的套件与聚合规则	CI 闸通过且具签名制品	质量保证负责人	P1
验收契约	场景阈值与例外	发布委员会使用版本化包	风险 + 产品	P1
安全内核 MVP	事件类型 + 强制 + 日志	相对基线可测的绕过率下降	运行时团队	P1
检索与工具策略	生产环境中介规则	相对红队目录事件下降	平台	P2
证据服务	关联标识、不可篡改	在时间预算内完成事件回放	SRE	P2

6.4 研究路线

主线: 综合。优先主题包括：异构栈上的组合式安全；带后悔界权衡的运行时可控性；经 validated 接口的策略—模型分离；借助统计与贝叶斯检验的非确定评测；安全—效用—时延多目标优化；以及在可行处将基准与形式主张相连的保证科学。

Key Takeaway

成熟项目同时交付控制、证据与学习：工程化强制、诚实测量，并通过可复现事故与基准叠加组织能力。

Chapter A

地域化与多语言评测

法域义务与语言引入与全球单一分数不可通约的风险语义。可行模式包括：带法域标签的本地化套件库；共享执行基础设施但类别、聚合与报告模板相异的并行轨道；语言感知检测器与分词陷阱；混合语言输入；以及从监管类别到测试义务的显式映射。证据包须标明轨道、套件版本及纳入统一发布决策板的理由。

Chapter B

术语与角色边界

安全判断提供方负责策略解释、风险评分、检测制品、可解释性载荷及适于审计的结构化证据。**执行平台**提供网络、扩缩容、编排 SLA 与负载管理。边界清晰可避免「任一侧均无法产出可回放轨迹」的归属真空。对外沟通时，内部项目命名宜映射至上述中性角色。